

INSTITUTO TECNOLÓGICO AUTÓNOMO DE MÉXICO (ITAM)

**FINANCIAL SENTIMENT RADAR EN AWS: PRODUCTO DE DATOS PARA MONITOREO
DE SENTIMIENTO FINANCIERO EN REDES SOCIALES Y DATOS EN TIEMPO REAL**

FAQ del producto

Integrantes:

Héctor Vilchis Peralta

Avril Salazar Rodríguez

Curso: Arquitectura de Productos de Datos y Métodos de Gran Escala

Profesor: Dante Guillermo Ruiz Martinez

1. ¿Qué tecnologías se utilizan?

La solución usa Python 3.12, pandas, scikit-learn, Plotly y Streamlit. En AWS usa Amazon S3 para data lake, Amazon ECR para imágenes Docker, Amazon ECS Fargate para ejecutar la app, Application Load Balancer para exponerla, IAM Roles para permisos, CloudWatch Logs para observabilidad y Amazon Bedrock para consultas y generación de respuestas, con fallback extractivo local si el servicio no responde. La infraestructura se define con AWS CloudFormation y el entorno local se administra con uv.

2. ¿Cómo se utiliza la solución?

El usuario abre la URL pública del Application Load Balancer. En la app puede revisar un resumen de sentimiento, hacer preguntas sobre el corpus, visualizar temas de riesgo y descargar datos procesados. Además, la aplicación incorpora una pestaña de tweets live, donde se monitorean publicaciones recientes capturadas desde Twitter/X y clasificadas automáticamente por sentimiento cada 2 horas. En la barra lateral también puede subir un CSV/Parquet con columna text o configurar búsquedas live mediante Twitter/X.

3. ¿Cómo se adquieren y usan los datos?

El producto acepta tres fuentes:

- Dataset de demo incluido en *data/sample_tweets.csv*.
- Archivo cargado por usuario con textos financieros.
- Twitter/X recent search para ingesta live, configurado mediante bearer token.

Después de la adquisición, el pipeline limpia texto, elimina URLs/menciones, extrae tickers o alias de empresa, clasifica sentimiento, asigna tema de negocio y guarda el dataset procesado.

En AWS se escribe en:

```
s3://<bucket>/processed/tweets/financial_sentiment_latest.parquet  
s3://<bucket>/raw/tweets/<tipo>_<timestamp>.parquet
```

4. ¿Qué analítica o inteligencia se aplica?

La inteligencia del MVP combina cuatro capas:

- **Extracción de entidades:** regex y diccionario de alias para tickers como NVDA, TSLA, AAPL, MSFT, BBVA.
- **Clasificación de sentimiento financiero mediante FinBERT.**
- **Temas de negocio:** reglas por keywords para earnings, tasas, AI/chips, lanzamientos, riesgo/compliance y acción de mercado.
- **Consulta de evidencia:** recuperación TF-IDF con similitud coseno. Si `USE_BEDROCK=true`, la evidencia recuperada se resume con Amazon Bedrock; si no, se genera una respuesta extractiva local.

5. ¿Cuáles son los inputs y outputs del producto?

Inputs

- CSV/Parquet con columna text.
- Opcional: *tweet_id,created_at,author,source*.
- Query live de Twitter/X si hay token.
- Pregunta del usuario en lenguaje natural.

Outputs

- Dashboard de sentimiento por ticker.
- Tendencia temporal de sentimiento.
- Tabla de temas con concentración negativa.
- Respuesta a preguntas con evidencia.
- Ranking live de tickers y tendencia temporal de tweets recientes.
- Dataset procesado descargable.
- Archivos procesados guardados en S3.
- Logs de operación en CloudWatch.

6. ¿Cómo consume el usuario final los outputs?

El usuario consume outputs en Streamlit. Puede ver gráficos, tablas, evidencia textual y descargar CSV. El instructor puede entrar a la URL pública del ALB sin ejecutar código. El equipo técnico puede auditar archivos S3 y logs CloudWatch.

7. ¿Cuánto costaría la solución a un año?

Escenario base de clase en *us-east-1*:

Servicio	Supuesto	Costo anual aproximado
ECS Fargate	1 task, 0.5 vCPU, 1 GB, 24/7	USD 216
Application Load Balancer	Cargo fijo + 1 LCU bajo tráfico	USD 267
Twitter/X API	10 tweets cada 2 horas $\approx$ 43,800 tweets/año; supuesto conservador de USD 0.05 por tweet	USD 2,190
Amazon S3	10 GB Standard	USD 3
Amazon ECR	2 GB imagen privada	USD 2
CloudWatch Logs	1 GB/mes	USD 6
Amazon Bedrock	Opcional, bajo volumen	USD 0-20
Total	Sin NAT Gateway ni RDS	USD 2,678 –2,698 anuales

El costo más relevante corresponde a la API de Twitter/X, ya que depende directamente del volumen de tweets consultados o ingeridos. Bajo el escenario de clase, considerando una ingesta aproximada de 10 tweets cada 2 horas y un supuesto conservador de USD 0.05 por tweet, el costo anual estimado sería cercano a USD 2,190. Por ello, el costo total anual de la solución aumentaría aproximadamente a USD 2,678–2,698. Este valor debe interpretarse como una estimación, ya que el precio real puede variar según el esquema vigente de la API y el volumen final de uso.

8. ¿Por qué no se usa Google Colab?

Porque el objetivo de la clase es transformar el análisis en un producto de datos productivo y reproducible. El pipeline corre localmente, en Docker y en AWS Fargate. Los modelos no dependen de notebooks de Colab.

9. ¿Qué modelo de sentimiento se utiliza?

Se utiliza FinBERT para clasificar sentimiento financiero. Como respaldo, la arquitectura mantiene procesamiento local y reglas auxiliares para temas, riesgo y evidencia.

10. ¿Qué componentes mínimos de la rúbrica cubre?

- Adquisición de datos: upload CSV/Parquet, dataset demo y Twitter/X live mediante bearer token.

- Preprocesamiento: limpieza, fechas, tickers, deduplicación.
- Analítica/inteligencia: sentimiento, temas, recuperación de evidencia y Bedrock opcional.
- Consumo: Streamlit público en ECS Fargate.
- AWS: S3, ECR, ECS Fargate, ALB, CloudFormation, IAM, CloudWatch Logs.

11. ¿Qué se debe subir a Canvas?

- product_definition.pdf
- product_faq.pdf
- architecture_solution.pdf
- architecture_financial_sentiment_radar.drawio
- presentacion_ejecutiva_15min.pptx
- URL pública de Streamlit
- URL del repositorio con acceso al instructor

12. ¿Qué riesgos o limitaciones tiene?

El producto no debe interpretarse como recomendación financiera. Las publicaciones en redes sociales pueden contener ruido, bots, ironía, ambigüedad y sesgos, lo cual puede afectar la clasificación de sentimiento. El alcance del MVP es demostrar arquitectura, trazabilidad y experiencia de producto; no maximizar accuracy de NLP.